Министерство науки и высшего образования Российской Федерации

ФГАОУ ВО «Севастопольский государственный университет»

Институт информационных технологий

Лабораторная работа №2
«Корреляционный и регрессионный анализ данных»

по дисциплине «Интеллектуальный анализ данных»
для студентов всех форм обучения направления подготовки
09.03.02 «Информационные системы и технологии»

Севастополь
2024

Корреляционный и регрессионный анализ данных. Методические указания к лабораторным занятиям по дисциплине «Интеллектуальный анализ данных» / Сост.: И.В. Дымченко, И.П. Шумейко, О.А. Сырых – Севастополь: Изд-во СевГУ, 2017 – 8 с.

Методические указания предназначены для проведения лабораторных работ по дисциплине «Интеллектуальный анализ данных». Целью методических указаний является помощь студентам в изучении возможностей языка R для интеллектуального анализа данных. Излагаются практические сведения необходимые для выполнения лабораторной работы.

Методические указания рассмотрены и утверждены на методическом семинаре и заседании кафедры «Информационные системы» (протокол № 1 от 30 августа 2024 г.)

Лабораторная работа №2.4
Корреляционный и регрессионный анализ данных. Множественная линейная регрессия.

Цель:

– исследовать возможности языка R для построения множественной линейной регрессий.

Время: 2 часа

Лабораторное оборудование: персональные компьютеры, выход в сеть Internet, RStudio.

Краткие теоретические сведения

Когда в регрессионной модели есть одна зависимая и одна независимая переменная, такой подход называется простой линейной регрессией. Когда есть одна зависимая переменная, но в модель входят ее степени (например, X, X^2, X^3), это называется полиномиальной регрессией. Если есть больше одной независимой переменной, это называется множественной регрессией.

Множественная линейная регрессия

Если существует больше одной независимой переменной, простая линейная регрессия превращается во множественную линейную регрессию, а ход вычислений становится более сложным.

Множественная линейная регрессия позволяет изучить совместное воздействие нескольких независимых переменных на переменную отклика. Практическое применение двоякое: для предсказания переменной отклика и для определения интенсивности, с которой каждая независимая переменная линейно связана с зависимой. В общем случае уравнение множественной линейной регрессии имеет вид:

$$y = b_0 + b_1x_1 + b_2x_2... + b_kx_k .$$

Если существует больше одной независимой переменной, то регрессионные коэффициенты показывают, на сколько увеличится значение зависимой переменной при изменении данной независимой переменной на единицу при условии, что все остальные независимые переменные останутся неизменными.

Важным дополнительным условием является некоррелированность объясняющих переменных между собой (отсутствие мультиколлинеарности). Считается, что явление мультиколлинеарности наблюдается тогда, когда коэффициент корреляции между объясняющими переменными превышает по модулю 0,7.

Пошаговая множественная линейная регрессия

Существуют две методики построения множественной регрессии – пошаговая вперед и пошаговая назад.

Пошаговая вперед заключается в то, что первоначально строится модель с одной экзогенной переменной. Затем добавляется следующая и строится новая модель. Модели сравниваются и, в зависимости от того ухудшилась или улучшилась модель, введенная переменная либо остается в модели, либо заменяется на другую. Таким образом, перебираются различные комбинации экзогенных переменных, в результате получается наилучшая модель.

Пошаговая назад начинается с того, что рассчитывается множественная регрессия на всем множестве факторов. Затем построенная модель исследуется с точки зрения статистической

значимости модели в целом, статистической значимости коэффициентов регрессии, оценивается коэффициент детерминации. Затем из модели удаляется один из влияющих факторов.

Его выбор можно осуществить следующим образом:

1. Строится матрица парных коэффициентов корреляции между переменными.

2. Выбираются две экзогенные переменные, между которыми наибольший коэффициент парной корреляции.

3. Из этих двух переменных выбирается та, которая оказывает меньшее влияние на эндогенную переменную, и исключается из модели.

Затем строится новая модель, исследуется ее качество. Также проводится тест на лучшую из двух моделей: с меньшим или большим числом переменных. В конце получается наилучшая модель.

Результат применения метода пошаговой регрессии зависит от критериев включения или удаления переменных. При помощи функции `stepAIC()` из пакета MASS можно провести построение пошаговой регрессии с использованием точного критерия AIC (Akaike Information Criterion – информационный критерий Акаике).

При расчете этого критерия учитывается статистическое соответствие модели данным и число необходимых для достижения этого соответствия параметров. Предпочтение нужно отдавать моделям с **меньшими** значениями AIC, указывающими на хорошее соответствие данным при использовании меньшего числа параметров**.**

Мультиколлинеарность

Наибольшие затруднения в использовании аппарата множественной регрессии возникают при наличии мультиколлинеарности факторных переменных, когда более чем два фактора связаны между собой линейной зависимостью.

Мультиколлинеарностью для линейной множественной регрессии называется наличие линейной зависимости между факторными переменными, включёнными в модель.

Мультиколлинеарность – нарушение одного из основных условий, лежащих в основе построения линейной модели множественной регрессии.

Мультиколлинеарность можно выявить на начальном этапе моделирования (до построения регрессии). О ней могут свидетельствовать:

1. Большие (по абсолютной величине) парные коэффициенты корреляции между независимыми переменными.

2. Высокие (>10) значения коэффициента *VIF*.

Коэффициент *VIF* (variance inflation factor) характеризует силу мультиколлинеарности. Вычисление коэффициента выполняется с помощью функции `vif()`

Симптомами присутствия мультиколлинеарности в уже построенной модели являются:

1. Небольшое изменении исходных данных, приводит к существенному изменению оценок коэффициентов.

2. Каждая переменная в отдельности является незначимой, а уравнение в целом имеет высокий R^2 (коэффициент детерминации) и является значимым.

3. Оценки коэффициентов имеют неправильные с точки зрения экономической теории знаки или неоправданно большие значения

Задание и порядок выполнения лабораторной работы №2.4

Построение множественной линейной регрессии

1. Запустить пакет R commander (Rcmdr).
2. Загрузить данные для анализа из файла Данные.xlsx
3. Провести подгонку множественной регрессионной модель при помощи функции lm() (рис 1):

– Статистики
– Подгонка моделей
– Линейная регрессия

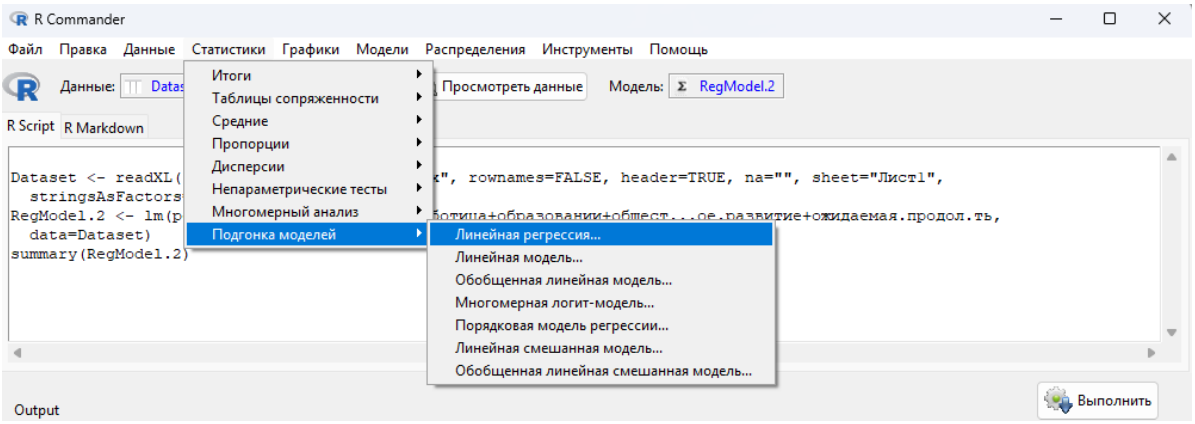

Рисунок 1 – Построение множественной регрессии

В появившемся диалоговом окне укажите: зависимая переменная – индекс реального ВВП, независимые – остальные индексы (рис 2).

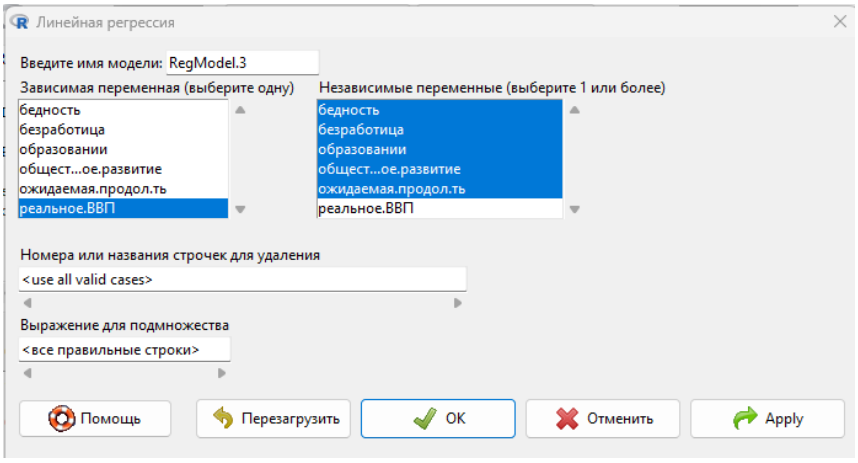

Рисунок 2 – Выбор переменных для множественной регрессии

По таблице коэффициентов (рис 3) запишите полученное уравнение регрессии, проанализируйте полученные коэффициенты регрессии.

```
Residuals:
       Min         1Q     Median         3Q        Max
-0.0024957 -0.0010437 -0.0001163  0.0013104  0.0022261

Coefficients:
                     Estimate Std. Error  t value Pr(>|t|)
(Intercept)           0.003094   0.014921    0.207    0.837
бедность             -1.008500   0.006849 -147.255   <2e-16 ***
безработица          -0.995791   0.009717 -102.484   <2e-16 ***
образовании          -1.006051   0.012020  -83.699   <2e-16 ***
общест...ое.развитие  5.008453   0.019866  252.106   <2e-16 ***
ожидаемая.продол.ть  -1.001116   0.010842  -92.337   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.001502 on 48 degrees of freedom
Multiple R-squared:  0.9996, Adjusted R-squared:  0.9996
F-statistic: 2.69e+04 on 5 and 48 DF,  p-value: < 2.2e-16
```

Рисунок 3 – Результат построения множественно регрессии

Обозначения

– Первый столбец (без заголовка) – свободный член (`intercept`) и предикторы в модели;

– `Estimate` – коэффициент регрессии;

– `Std. Error` – стандартная ошибка коэффициента регрессии;

– `t value` – t-статистика, с помощью которой проверяют статистическую гипотезу отличия коэффициента регрессии от 0;

– `Pr(>|t|)` – уровень значимости предиктора, статистически значимые предикторы помечены звёздочками;

– `Residual standard error` – остаточная стандартная ошибка – показатель разброса возможных значений случайной ошибки;

– `Multiple R-squared` – коэффициент детерминации, или квадрат коэффициента множественной корреляции модели;

– `Adjusted R-squared` –скорректированный коэффициент детерминации;

– `F-statistic` – F-статистика, оценивающая значимость полученной модели множественной линейной регрессии в целом, и её уровень значимости.

Итоговое уравнение множественной регрессии имеет вид:

*индекс реального ВВП = 5*общественное развитие – бедность – 0,99*безработица – образование – ожид.продолжительность + 0,003*

4. Проанализируйте графики остатков (наблюдаемое минус предсказанное регрессионной моделью значение).

– Модели

– Графики

– График Компонента + остаток (рис 4)

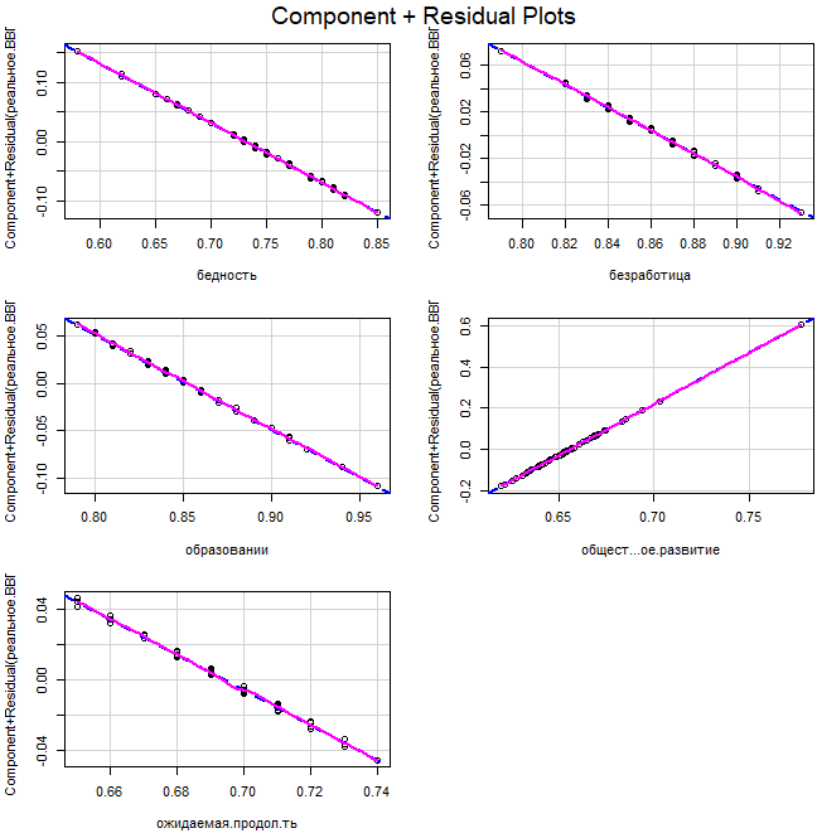

Рисунок 4 – График Компонента + остаток

5. Выполнить пошаговое построение регрессии (рис 5):

– Модели

– Ступенчаты выбор модели

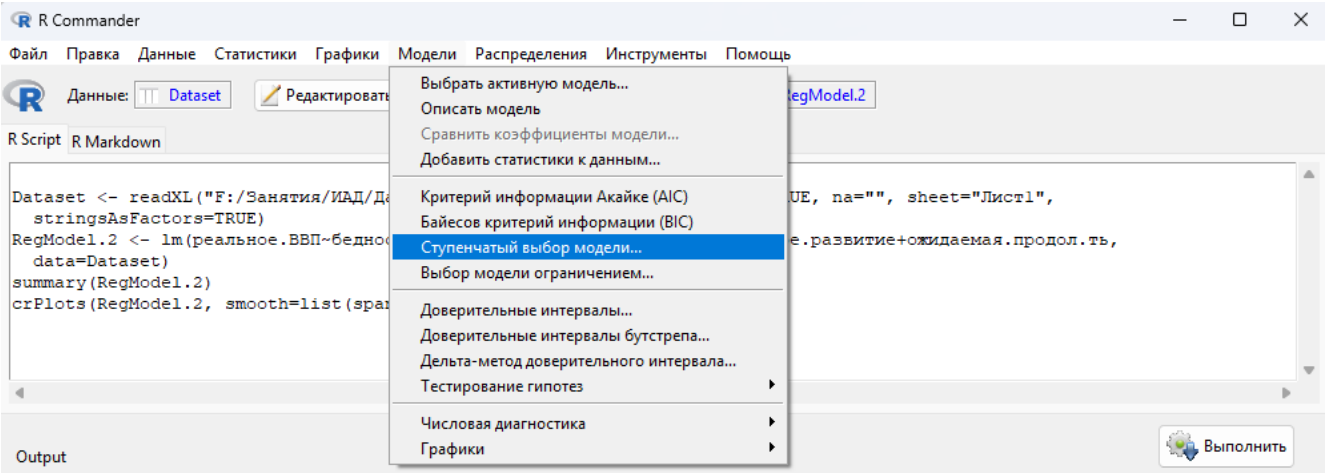

Рисунок 5 – Пошаговое построение регрессии

В открывшемся окне выбрать коэффициент AIC, направление вперед (рис 6)

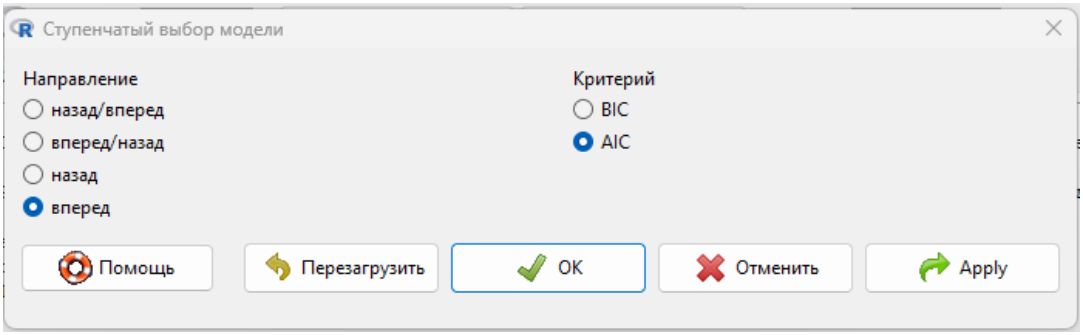

Рисунок 6 – Ступенчатый выбор модели

6. По полученным результатам (рис 7, 8) записать уравнение множественно регрессии.

```
Start:  AIC=-277.78
реальное.ВВП ~ 1

                      Df Sum of Sq      RSS     AIC
+ общест...ое.развитие  1  0.208363 0.095211 -338.39
+ образовании           1  0.119979 0.183595 -302.94
+ бедность              1  0.012333 0.291240 -278.02
+ безработица           1  0.012102 0.291471 -277.98
<none>                             0.303574 -277.78
+ ожидаемая.продол.ть   1  0.007112 0.296461 -277.06

Step:  AIC=-338.39
реальное.ВВП ~ общест...ое.развитие

                       Df Sum of Sq      RSS     AIC
+ бедность              1  0.056599 0.038612 -385.13
+ образовании           1  0.030942 0.064269 -357.62
+ ожидаемая.продол.ть   1  0.027114 0.068096 -354.49
+ безработица           1  0.025511 0.069699 -353.24
<none>                              0.095211 -338.39

Step:  AIC=-385.13
реальное.ВВП ~ общест...ое.развитие +
    бедность

                       Df Sum of Sq      RSS     AIC
+ ожидаемая.продол.ть  1 0.0135668 0.025045 -406.51
+ безработица          1 0.0131487 0.025463 -405.61
<none>                              0.038612 -385.13
+ образовании          1 0.0002199 0.038392 -383.44
```

```
Step:  AIC=-406.51
реальное.ВВП ~ общест...ое.развитие +
    бедность + ожидаемая.продол.ть

              Df Sum of Sq      RSS     AIC
+ безработица  1 0.0091321 0.015913 -429.00
+ образовании  1 0.0012418 0.023803 -407.25
<none>                     0.025045 -406.51

Step:  AIC=-429
реальное.ВВП ~ общест...ое.развитие +
    бедность + ожидаемая.продол.ть +
    безработица

              Df Sum of Sq       RSS     AIC
+ образовании  1  0.015805 0.0001083 -696.46
<none>                     0.0159129 -429.00

Step:  AIC=-696.46
реальное.ВВП ~ общест...ое.развитие +
    бедность + ожидаемая.продол.ть +
    безработица + образовании
```

Рисунок 7 – Выбор оптимальной модели

```
Call:
lm(formula = реальное.ВВП ~ общест...ое.развитие +
    бедность + ожидаемая.продол.ть +
    безработица + образовании, data = Dataset)

Coefficients:
        (Intercept)  общест...ое.развитие              бедность   ожидаемая.продол.ть           безработица
           0.003094             5.008453            -1.008500             -1.001116             -0.995791
         образовании
          -1.006051
```

Рисунок 8 – Результат пошагового построения множественной регрессии вперед

Итоговое уравнение множественной регрессии при построении вперед имеет вид:

*индекс реального ВВП = 5*общественное развитие – бедность – 0,99*безработица – образование – ожид.продолжительность + 0,003*

7. Аналогично сделать пошаговое построение по направлению назад, сравнить с предыдущим построением, сделать выводы.
8. Проверить коэффициент VIF (рис 9,10) и сделать выводы
– Модели
– Числовая диагностика
– Факторы, влияющие на дисперсию

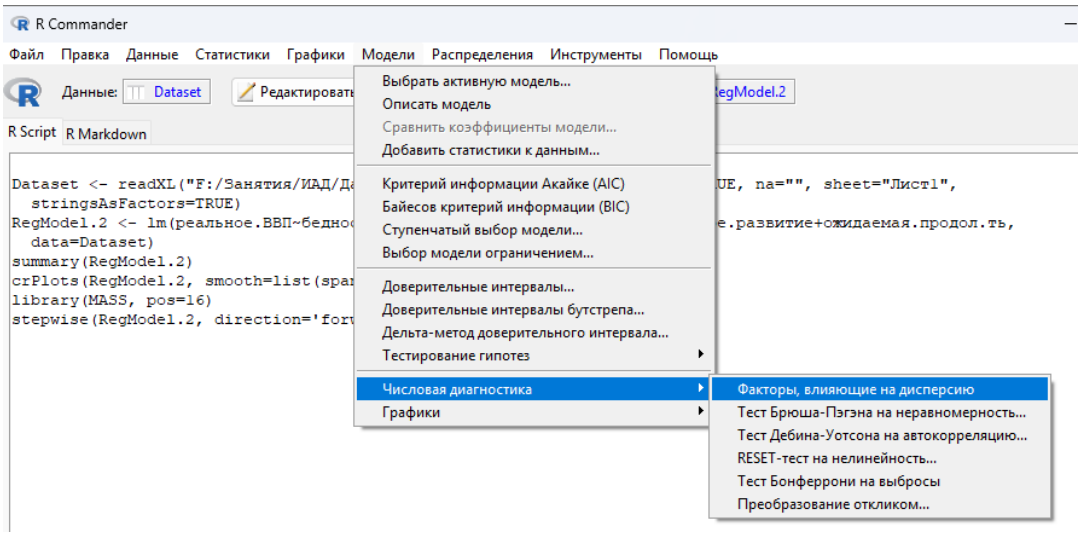

Рисунок 9 – Проверка коэффициента VIF

```
> vif(RegModel.2)
          бедность         безработица         образовании общест...ое.развитие  ожидаемая.продол.ть
          3.929637            1.845679            4.696324             5.630180             1.309560
```

Рисунок 10 – Результат проверка коэффициента VIF

Исходя из полученных коэффициентов VIF можно сделать вывод об отсутствии мультиколлинеарности в построенной модели.

9. Загрузить экспериментальные данные.
10. Построить множественную линейную регрессию. По таблице коэффициентов записать полученное уравнение регрессии. Проанализируйте график остатков.
11. Выполнить пошаговое построение множественной регрессии по направлению назад /вперед сравнить полученные результаты, провести проверку коэффициента VIF, сделать выводы.

Содержание отчета

Отчет по выполняемой лабораторной работе выполняется каждым студентом индивидуально на листах формата А4 в рукописном или машинном варианте исполнения и должен содержать:

- название работы;
- цель и задачи исследований;
- набор экспериментальных данных;
- выводы по построенной множественной регрессии;
- программный код с комментариями;
- выводы по работе.

Контрольные вопросы

1. Множественная регрессия
2. Пошаговая множественная регрессия
3. Мультиколлинеарность.