

Министерство науки и высшего образования Российской Федерации
ФГАОУ ВО «Севастопольский государственный университет»

Институт информационных технологий

Лабораторная работа №5

«Линейный дискриминантный анализ. Построение канонических и классификационных функций»

по дисциплине «Интеллектуальный анализ данных»
для студентов всех форм обучения направления подготовки
09.03.02 «Информационные системы и технологии»

Севастополь
2024

Линейный дискриминантный анализ. Построение канонических и классификационных функций. Методические указания к лабораторным занятиям по дисциплине «Интеллектуальный анализ данных» / Сост.: О.А. Сырых – Севастополь: Изд-во СевГУ, 2019 – 6 с.

Методические указания предназначены для проведения лабораторных работ по дисциплине «Интеллектуальный анализ данных». Целью методических указаний является помощь студентам в изучении возможностей языка R для интеллектуального анализа данных. Излагаются практические сведения необходимые для выполнения лабораторной работы.

Методические указания рассмотрены и утверждены на методическом семинаре и заседании кафедры «Информационные системы» (протокол № 1 от 30 августа 2024 г.)

Лабораторная работа №5_1

Линейный дискриминантный анализ. Построение канонических и классификационных функций.

Цель:

- Закрепить теоретические знания и приобрести практические навыки в проведении дискриминантного анализа по экспериментальным данным
- исследовать возможности языка R для проведения дискриминантного анализа.

Время: 2 часа

Лабораторное оборудование: персональные компьютеры, выход в сеть Internet, RStudio.

Краткие теоретические сведения

Дискриминантный анализ

С помощью дискриминантного анализа на основании некоторых признаков (независимых переменных) объект может быть причислен к одной из двух или нескольких групп (число групп определяется числом категорий зависимой переменной). В двумерном дискриминантном анализе объекты относятся к одной из двух групп, например, купившие или не купившие данный продукт. А независимыми переменными в этом случае выступают возраст, доход покупателей, и др. показатели.

Дискриминантный анализ используется для анализа данных в том случае, когда зависимая переменная категориальная, а предикторы (независимые переменные) – интервальные. В результате дискриминантного анализа строится так называемая каноническая дискриминантная функция

$$d = b_1x_1 + b_2x_2 + \dots + b_nx_n$$

где x_1 и x_n – значения дискриминантных переменных, соответствующих рассматриваемым случаям, $b_1 \dots b_n$ – коэффициенты, которые и предстоит оценить с помощью дискриминантного анализа. Коэффициенты подбираются так, чтобы по значениям дискриминантной функции можно было с максимальной четкостью провести разделение по группам.

Процедура дискриминантного анализа состоит из пяти шагов. Первый шаг – формулирование проблемы, требует определения целей, зависимой и независимых переменных. Выборку делят на две части. Анализируемую выборку используют для вычисления дискриминантной функции; проверочную – для проверки достоверности модели. Второй шаг – определение функции, включает выведение такой линейной комбинации предикторов (дискриминантных функций), чтобы группы максимально возможно различались между собой значениями предикторов.

Определение статистической значимости представляет собой третий шаг. Она включает проверку нулевой гипотезы о том, что в совокупности средние всех дискриминантных функций во всех группах равны между собой. Если нулевую гипотезу отклоняют, то имеет смысл интерпретировать результаты.

Четвертый шаг – интерпретация дискриминантных весов или коэффициентов аналогична такой же стадии во множественном регрессионном анализе.

Пятый шаг – проверка достоверности. Она включает разработку классификационной матрицы. Дискриминантные веса, определенные с помощью анализируемой выборки, умножают на значения независимых переменных в проверочной выборке, чтобы получить дискриминантные показатели для случаев в этой выборке. Затем случаи распределяют по группам, исходя из дискриминантных показателей и соответствующего правила принятия решения. Определяют процент верно классифицированных случаев и сравнивают его с процентом случаев, которое можно ожидать на основе классификации методом случайного выбора.

Для оценки коэффициентов существует два известных подхода. Прямой метод включает оценку дискриминантной функции при одновременном введении всех предикторов. Альтернативный ему пошаговый метод включает последовательное введение предсказанных переменных, исходя из их способности дискриминировать группы.

Задание и порядок выполнения лабораторной работы №5_1

Проведение дискриминантного анализа и интерпретация результатов в среде R

Дискриминантный анализ реализован в нескольких пакетах для R, в данной работе будет рассмотрено применение функции `lda()` из базового пакета MASS.

Все процедуры дискриминантного анализа можно разбить на две группы: первая группа позволяет интерпретировать различия между имеющимися группами (сравнивая средние), вторая – проводить классификацию новых объектов в тех случаях, когда неизвестно заранее, к какому из существующих классов они принадлежат.

1. Подготовка данных для дискриминантного анализа. Для проведения дискриминантного анализа необходимо иметь разделение исходных данных на группы (классы). В данной работе в качестве классов (групп) возьмем разбиение выборки на кластеры. Количество кластеров было определено в предыдущей работе.

2. Создать тренировочную выборку из исходных данных с известной группировкой. Для того чтобы работать с методами классификации с обучением, надо сначала освоить технику «обучения». Для этого выбирается часть данных с известной групповой принадлежностью. На основании анализа этой части (тренировочной выборки) строится гипотеза о том, как должны распределяться по группам остальные, неклассифицированные данные

3. Создать выборку оставшихся данных для последующей проверки классификации

4. Провести дискриминантный анализ по тренировочной выборке используя функцию `lda ()`

5. По полученным данным составить дискриминантную функцию

$$d = b_1x_1 + b_2x_2 + \dots + b_nx_n$$

6. Провести классификацию оставшихся данных и построить матрицу неточностей.

7. По полученным результатам сделать выводы.

Пример выполнения работы

Провести дискриминантный анализ и проверку построенной модели на экспериментальных данных.

1. Подготовка данных для дискриминантного анализа:

Загрузить файл Данные.xls

Провести кластерный анализ методом k-средних на 4 кластера (согласно проведенному анализу в лабораторной работе 4)

Результаты разбиения на кластеры добавить к данным (рисунки 1,2).




Рисунок 1 – Кластерный анализ данных

	...1 ожидаемая.продол.ть образования	бедность	безработица	реальное.ВВП	общест...ое.развитие	KMeans		
1	Тюменская область	0.71	0.91	0.85	0.86	0.555	0.777	4
2	Самарская область	0.71	0.88	0.82	0.91	0.193	0.703	1
3	Мурманская область	0.73	0.92	0.82	0.79	0.208	0.694	1
4	Республика Татарстан	0.73	0.85	0.80	0.89	0.157	0.685	3
5	Республика Коми	0.69	0.90	0.79	0.82	0.216	0.683	1
6	Республика Якутия	0.67	0.91	0.68	0.86	0.296	0.683	1
7	Магаданская область	0.69	0.96	0.66	0.82	0.245	0.675	1
8	Хабаровский край	0.66	0.91	0.75	0.88	0.172	0.674	1
9	Пермская область	0.69	0.84	0.79	0.87	0.164	0.671	3
10	Белгородская область	0.74	0.81	0.80	0.89	0.115	0.671	3
11	Липецкая область	0.72	0.81	0.81	0.89	0.119	0.670	3
12	Московская область	0.70	0.88	0.73	0.90	0.134	0.669	3
13	Камчатская область	0.66	0.94	0.67	0.82	0.250	0.668	1
14	Нижегородская область	0.70	0.82	0.79	0.91	0.125	0.669	3
15	Ульяновская область	0.72	0.82	0.81	0.89	0.097	0.667	3
16	Красноярский край	0.65	0.86	0.77	0.84	0.205	0.665	1
17	Ярославская область	0.70	0.83	0.76	0.89	0.137	0.663	3
18	Томская область	0.69	0.86	0.73	0.85	0.174	0.661	1
19	Иркутская область	0.65	0.88	0.73	0.86	0.167	0.657	1
20	Вологодская область	0.69	0.82	0.75	0.87	0.159	0.658	3
21	Кемеровская область	0.66	0.84	0.77	0.88	0.138	0.658	3
22	Ростовская область	0.71	0.86	0.79	0.84	0.078	0.656	3
23	Тульская область	0.68	0.83	0.79	0.88	0.093	0.655	3
24	Респ. Башкортостан	0.71	0.84	0.72	0.87	0.137	0.655	3
25	Воронежская область	0.73	0.81	0.75	0.91	0.083	0.657	3
26	Челябинская область	0.71	0.85	0.73	0.88	0.112	0.656	3
27	Свердловская область	0.69	0.86	0.67	0.90	0.152	0.654	2
28	Курская область	0.70	0.81	0.74	0.90	0.110	0.652	3

Рисунок 2 – Разбиение данных на кластеры

2. Создание тренировочной выборки

Создадим выборку строк от 1 до последней с шагом 5 (рисунок 3)

```
Dataset.train <- Dataset [seq (1, nrow(Dataset),5),]
Dataset.train
```

> Dataset.train										
	...	1	ожидаемая.продол.ть	образовании	бедность	безработица	реальное.ВВП	общест...ое.развитие	KMeans	
1			Тюменская область	0.71	0.91	0.85	0.86	0.555	0.777	4
6			Республика Якутия	0.67	0.91	0.68	0.86	0.296	0.683	1
11			Липецкая область	0.72	0.81	0.81	0.89	0.119	0.670	3
16			Красноярский край	0.65	0.86	0.77	0.84	0.205	0.665	1
21			Кемеровская область	0.66	0.84	0.77	0.88	0.138	0.658	3
26			Челябинская область	0.71	0.85	0.73	0.88	0.112	0.656	3
31			Республика Карелия	0.68	0.85	0.77	0.83	0.128	0.652	3
36			Краснодарский край	0.71	0.84	0.75	0.84	0.092	0.646	3
41			Приморский край	0.68	0.89	0.66	0.85	0.125	0.641	2
46			Тверская область	0.67	0.83	0.69	0.89	0.095	0.635	2
51			Брянская область	0.70	0.80	0.73	0.84	0.070	0.628	3

Рисунок 3 – Тренировочная выборка

Оставшиеся данные сформируем в выборку для последующей проверки полученной классификации (рисунок 4)

```
Dataset.unknown <- Dataset [-seq (1, nrow(Dataset),5),]
Dataset.unknown
```

		...1	ожидаемая.продол.ть	образовании	бедность	безработица	реальное.ВВП	общест...ое.развитие	KMeans
2	Самарская область		0.71	0.88	0.82	0.91	0.193	0.703	1
3	Мурманская область		0.73	0.92	0.82	0.79	0.208	0.694	1
4	Республика Татарстан		0.73	0.85	0.80	0.89	0.157	0.685	3
5	Республика Коми		0.69	0.90	0.79	0.82	0.216	0.683	1
7	Магаданская область		0.69	0.96	0.66	0.82	0.245	0.675	1
8	Хабаровский край		0.66	0.91	0.75	0.88	0.172	0.674	1
9	Пермская область		0.69	0.84	0.79	0.87	0.164	0.671	3
10	Белгородская область		0.74	0.81	0.80	0.89	0.115	0.671	3
12	Московская область		0.70	0.88	0.73	0.90	0.134	0.669	3
13	Камчатская область		0.66	0.94	0.67	0.82	0.250	0.668	1
14	Нижегородская область		0.70	0.82	0.79	0.91	0.125	0.669	3
15	Ульяновская область		0.72	0.82	0.81	0.89	0.097	0.667	3
17	Ярославская область		0.70	0.83	0.76	0.89	0.137	0.663	3
18	Томская область		0.69	0.86	0.73	0.85	0.174	0.661	1
19	Иркутская область		0.65	0.88	0.73	0.86	0.167	0.657	1

Рисунок 4 – Пример тестовой выборки

3. Проведение дискриминантного анализа (рисунок 5).

Включить пакет MASS

В качестве переменных используются столбцы 2:7, классификация проводится по столбцу 8:

```
dataset.lda <- lda (Dataset.train[, 2:7], Dataset.train[,8])
dataset.lda
```

```
Group means:
      ожидаемая.продол.ть  образовании  бедность  безработица  реальное.ВВП  общест...ое.развитие
1      0.6600000      0.8850000      0.725      0.85      0.2505000      0.6740000
2      0.6750000      0.8600000      0.675      0.87      0.1100000      0.6380000
3      0.6966667      0.8316667      0.760      0.86      0.1098333      0.6516667
4      0.7100000      0.9100000      0.850      0.86      0.5550000      0.7770000

Coefficients of linear discriminants:
              LD1      LD2      LD3
ожидаемая.продол.ть 1911.604 -281.2580 -634.5834
образованием      1854.339 -328.6316 -680.1751
бедность           2011.204 -316.2772 -700.4211
безработица       1889.075 -338.1576 -660.4936
реальное.ВВП      2102.380 -338.6539 -669.3860
общест...ое.развитие -9862.558 1664.3230 3379.6432

Proportion of trace:
      LD1      LD2      LD3
0.9910 0.0077 0.0013
```

Рисунок 5 – Результат дискриминантного анализа

4. Построение дискриминантных функций:

Для построения дискриминантных функций из проведенного анализ используются Коэффициенты линейных дискриминантов (рисунок 6)

```
Coefficients of linear discriminants:
              LD1      LD2      LD3
ожидаемая.продол.ть 1911.604 -281.2580 -634.5834
образованием      1854.339 -328.6316 -680.1751
бедность           2011.204 -316.2772 -700.4211
безработица       1889.075 -338.1576 -660.4936
реальное.ВВП      2102.380 -338.6539 -669.3860
общест...ое.развитие -9862.558 1664.3230 3379.6432
```

Рисунок 6 – Коэффициенты линейных дискриминантов

Исходя из результатов получаем три дискриминантные функции

$$1) \quad z(x) = 1912x_1 + 1854x_2 + 2011x_3 + 1889x_4 + 2102x_5 - 9863x_6$$

$$2) \quad z(x) = -218x_1 - 329x_2 - 316x_3 - 338x_4 - 339x_5 + 1664x_6$$

$$3) \quad z(x) = -635x_1 - 680x_2 - 700x_3 - 660x_4 - 669x_5 + 3380x_6$$

5. Провести классификацию и проверку оставшихся данных:

```
dataset.ldap <- predict(dataset.lda, Dataset.unknown[,
2:7])$class
dataset.ldap
```

Результат полученной классификации:

```
> dataset.ldap
[1] 2 2 2 2 1 4 2 2 1 3 2 2 1 4 1 2 2 1 1 1 2 2 1 1 4 1 1 2 1 2 3 2 4 2 2 1 1 1 3 1
Levels: 1 2 3 4
```

Для проверки созданной модели построим матрицу неточностей:

```
table (dataset.ldap, Dataset.unknown[, 8])
```

Результат:

```
dataset.ldap  1  2  3  4
1      8  8  1  1
2      2 11  0  5
3      2  0  1  0
4      0  2  0  2
```

По данной матрице видно, что тренировочная выборка привела к построению гипотезы, по которой 21 объект попал не свой класс, следовательно, ошибка данной модели составляет 49%.

При высоком проценте ошибки построенной модели необходимо или увеличить количество элементов в обучающей выборке, или изменить количество кластеров и построить модель заново.

Контрольные вопросы

1. Понятие дискриминантного анализа.
2. Понятие дискриминантной функции.
3. Процедура дискриминантного анализа.