

Министерство науки и высшего образования Российской Федерации
ФГАОУ ВО «Севастопольский государственный университет»

Институт информационных технологий

Лабораторная работа №5

«Линейный дискриминантный анализ. Построение канонических и классификационных функций»

по дисциплине «Интеллектуальный анализ данных»
для студентов всех форм обучения направления подготовки
09.03.02 «Информационные системы и технологии»

Севастополь
2025

Линейный дискриминантный анализ. Построение канонических и классификационных функций. Методические указания к лабораторным занятиям по дисциплине «Интеллектуальный анализ данных» / Сост.: О.А. Сырых – Севастополь: Изд-во СевГУ, 2019 – 5 с.

Методические указания предназначены для проведения лабораторных работ по дисциплине «Интеллектуальный анализ данных». Целью методических указаний является помощь студентам в изучении возможностей системы RStudio. Излагаются практические сведения необходимые для выполнения лабораторной работы, требования к содержанию отчета.

Методические указания рассмотрены и утверждены на методическом семинаре и заседании кафедры «Информационные системы» (протокол № 1 от 30 августа 2024 г.)

Лабораторная работа №5_2

Линейный дискриминантный анализ. Проведение дискриминантного анализа и интерпретация результатов.

Цель:

- Закрепить теоретические знания и приобрести практические навыки в проведении дискриминантного анализа по экспериментальным данным
- исследовать возможности языка R для проведения дискриминантного анализа.

Время: 2 часа

Лабораторное оборудование: персональные компьютеры, выход в сеть Internet, RStudio.

Краткие теоретические сведения

Дискриминантный анализ

С помощью дискриминантного анализа на основании некоторых признаков (независимых переменных) объект может быть причислен к одной из двух или нескольких групп (число групп определяется числом категорий зависимой переменной). В двумерном дискриминантном анализе объекты относятся к одной из двух групп, например, купившие или не купившие данный продукт. А независимыми переменными в этом случае выступают возраст, доход покупателей, и др. показатели.

Дискриминантный анализ используется для анализа данных в том случае, когда зависимая переменная категориальная, а предикторы (независимые переменные) – интервальные. В результате дискриминантного анализа строится так называемая каноническая дискриминантная функция

$$d = b_1x_1 + b_2x_2 + \dots + b_nx_n$$

где x_1 и x_n – значения дискриминантных переменных, соответствующих рассматриваемым случаям, $b_1 \dots b_n$ – коэффициенты, которые и предстоит оценить с помощью дискриминантного анализа. Коэффициенты подбираются так, чтобы по значениям дискриминантной функции можно было с максимальной четкостью провести разделение по группам.

Процедура дискриминантного анализа состоит из пяти шагов. Первый шаг – формулирование проблемы, требует определения целей, зависимой и независимых переменных. Выборку делят на две части. Анализируемую выборку используют для вычисления дискриминантной функции; проверочную – для проверки достоверности модели. Второй шаг – определение функции, включает выведение такой линейной комбинации предикторов (дискриминантных функций), чтобы группы максимально возможно различались между собой значениями предикторов.

Определение статистической значимости представляет собой третий шаг. Она включает проверку нулевой гипотезы о том, что в совокупности средние всех дискриминантных функций во всех группах равны между собой. Если нулевую гипотезу отклоняют, то имеет смысл интерпретировать результаты.

Четвертый шаг – интерпретация дискриминантных весов или коэффициентов аналогична такой же стадии во множественном регрессионном анализе.

Пятый шаг – проверка достоверности. Она включает разработку классификационной матрицы. Дискриминантные веса, определенные с помощью анализируемой выборки, умножают на значения независимых переменных в проверочной выборке, чтобы получить дискриминантные показатели для случаев в этой выборке. Затем случаи распределяют по группам, исходя из дискриминантных показателей и соответствующего правила принятия решения. Определяют процент верно классифицированных случаев и сравнивают его с процентом случаев, которое можно ожидать на основе классификации методом случайного выбора.

Для оценки коэффициентов существует два известных подхода. Прямой метод включает оценку дискриминантной функции при одновременном введении всех предикторов. Альтернативный ему пошаговый метод включает последовательное введение предсказанных переменных, исходя из их способности дискриминировать группы.

Задание и порядок выполнения лабораторной работы №5_2

Проведение дискриминантного анализа и интерпретация результатов в среде R

При проведении дискриминантного анализа может возникнуть вопрос, какие из имеющихся признаков являются информативными при разделении, а какие – сопутствующим балластом.

По построенной модели необходимо вывести важные показатели для оценки ее качества: матрицу неточностей на обучающей выборке, ошибку распознавания и расстояние Махаланобиса между центроидами двух классов

1. Провести шаговую процедуру выбора переменных для построения дискриминантной модели.
2. Построить дискриминантную модель с выбранными переменными, составить уравнение дискриминантной функции.
3. Вывести показатели оценки качества построенной модели: матрица неточностей, ошибку распознавания, расстояние Махаланобиса.
4. Сделать выводы по построенной модели. Сравнить полученные результаты с моделью в которой использовались все переменные (работа 5.1).
5. Добавить в исходную выборку данные без классификации и используя дискриминантный анализ провести классификацию.

Пример выполнения работы

1. Провести шаговую процедуру выбора переменных для построения дискриминантной модели.

Шаговая процедура выбора переменных при классификации реализована функцией `stepclass()` из пакета `klaR`. Результат представлен на рисунке 1.

```
stepclass(Dataset[,2:7], Dataset[,8], method = "lda")
```

```

> stepclass(Dataset[,2:7], Dataset[,8], method ="lda")
correctness rate: 0.65333; in: "реальное.ВВП"; variables (1): реальное.ВВП
correctness rate: 0.88; in: "бедность"; variables (2): реальное.ВВП, бедность

hr.elapsed min.elapsed sec.elapsed
0.00      0.00      0.19

method      : lda
final model : Dataset[, 8] ~ бедность + реальное.ВВП
<environment: 0x000001a377ab53f0>

correctness rate = 0.88

```

Рисунок 1 – Результат процедуры выбора переменных

Исходя из результатов выбора переменных для построения дискриминантной модели будут использоваться только две переменные «Бедность» и «Реальное ВВП»

2. Построить дискриминантную модель с выбранными переменными, составить уравнение дискриминантной функции (проделать все шаги из части 5.1, но с учетом оставшихся переменных).

```

dataset.lda <- lda (Dataset.train[c(4,6)], Dataset.train[,8])
dataset.lda

```

```

Prior probabilities of groups:
      1      2      3      4
0.1818182 0.3636364 0.1818182 0.2727273

Group means:
      бедность реальное.ВВП
1      0.765      0.42550
2      0.755      0.09825
3      0.675      0.11000
4      0.770      0.15700

Coefficients of linear discriminants:
      LD1      LD2
бедность -30.21474 18.9605581
реальное.ВВП 25.04333 0.1108117

Proportion of trace:
      LD1      LD2
0.9499 0.0501

```

Рисунок 2 – Результат дискриминантного анализа

Исходя из результатов дискриминантного анализа получаем две дискриминантные функции

$$1) \quad z(x) = 25x_1 - 30x_2$$

$$2) \quad z(x) = 18x_1 + 0,11x_2$$

Проведем классификацию и проверку оставшихся данных:

```

dataset.ldap <- predict(dataset.lda, Dataset.unknown[c(4,6)])$class
dataset.ldap

```

Результат полученной классификации:

```
> dataset.ldap
[1] 2 4 2 4 1 4 2 2 4 1 2 2 4 3 3 4 2 2 4 2 3 2 2 2 2 4 2 4 3 2 3 4 1 2 2 2 4 3 3 3 3 3 3
Levels: 1 2 3 4
```

3. Вывести показатели оценки качества построенной модели: матрица неточностей, ошибку распознавания, расстояние Махаланобиса.

```
table (dataset.ldap, Dataset.unknown[,8])
```

```
> table (dataset.ldap, Dataset.unknown[,8])
```

```
dataset.ldap  1  2  3  4
             1  2  0  1  0
             2  0 15  0  3
             3  0  0  9  2
             4  0  4  2  5
```

```
Err_S <- mean (Dataset.unknown[,8] != dataset.ldap)
```

```
> Err_S <- mean (Dataset.unknown[,8] != dataset.ldap)
```

```
> Err_S
[1] 0.2790698
```

```
mahDist <- dist(dataset.lda$means %*% dataset.lda$scaling)
```

```
> mahDist
      1      2      3
2 7.896512
3 5.466627 3.106246
4 6.875514 1.058824 2.476042
```

4. Сделать выводы по построенной модели. Сравнить полученные результаты с моделью в которой использовались все переменные (построенной в работе 5.1).

Исходя из сравнительного анализ двух моделей можно увидеть, что удаление переменных из модели привело к снижению процента ошибки (с 49% до 28%)

5. Добавить в выборку данные без классификации (рисунок 3), используя дискриминантный анализ провести классификацию.

55	111	0.71	0.87	0.69	0.84	0.092	0.631	0
56	222	0.65	0.91	0.73	0.83	0.085	0.642	0
57	333	0.68	0.68	0.73	0.87	0.095	0.620	0
58	444	0.71	0.85	0.70	0.93	0.110	0.626	0

Рисунок 3 – Данные без классификации

Результат полученной классификации:

```
> dataset.ldap
[1] 4 4 2 4 1 4 4 2 3 1 2 2 2 3 4 3 4 4 2 2 3 2 2 2 3 3 4 2 2 3 2 2 1 2 2 2 4 3 1 3 3 2 2 2 4 1 2
Levels: 1 2 3 4
```

```
> table (dataset.ldap, Dataset.unknown[,8])
dataset.ldap  0  1  2  3  4
             1  1  2  0  2  0
             2  2  0 13  5  1
             3  0  0  3  4  3
             4  1  0  3  1  6
```

Исходя из результатов классификации и матрицы неточностей, можно сделать выводы, что элемент один элемент попал в первый класс, два – во второй и еще один в четвертый.

Контрольные вопросы

1. Понятие дискриминантного анализа.
2. Понятие дискриминантной функции.
3. Процедура дискриминантного анализа.